数理统计讲义

minamomo

Tuesday 31st March, 2026

References:

[1] 数理统计 (第三版), 韦来生, 2025.

Marks:

1. 样本空间 $\mathscr{X}$.

Preface

“正如概率论是数学分析的习题课, 数理统计是数学分析和概率论的习题课的感觉一样.”

minamomo

2026.3 于中国上海

This page intentionally left blank.

Contents

1 统计学基础 **7**

1.1 样本与分布 7

1.2 正态分布的统计量 12

1.3 χ^2 分布, t 分布与 F 分布 15

1.3.1 χ^2 分布 15

1.3.2 t 分布 18

1.3.3 F 分布 20

2 统计估计 **23**

3 假设检验 **25**

4 决策理论 **27**

This page intentionally left blank.

Chapter 1

统计学基础

1.1 样本与分布

概率论所研究对象是以各种形式给出的分布, 包括概率 P, 分布 F 以及密度 f, 连同分布的各种特征, 包括期望 $\mathbb{E}$, 方差 Var, 协方差 Cov 等. 总而言之, 概率论的目标在于对给定的分布, 分析这个分布下随机事件发生的特征并加以描述.

统计学的目标则恰恰相反. 统计学的研究对象是概率论的研究结果, 即实际发生的随机事件, 而统计学的研究目标则是概率论的研究对象, 即分析随机事件数据服从的分布. 对分布本身加以估计, 就称为统计估计, 对分布带来的结果加以估计, 就称为假设检验, 应用估计的结果, 就称为决策理论.

Definition 1.1.(总体和样本) **总体 (population)** 是指研究对象所满足的, 实际上的分布 F. 总体分布在实际问题中往往是存在但未知的. 服从总体分布的随机变量称为**样本 (sample)**. 样本往往被认为是已知的. 样本的所有可能取值的集合称为**样本空间 (sample space)**.

统计学的一个目标是通过样本还原总体分布, 即将总体分布近似地表示成样本 $\{X_k\}_{k=1}^n$ 的函数.

作为例子, 我们来看概率论是如何通过分布分析随机事件的特征的.

Example 1.1.(正态分布的总体方差) 给定 n 维随机向量 $\mathbf{X}$, 每个分量独立同分布, 服从正态分布 $N(\mu, \sigma^2)$, 通过这些随机变量可以构造若干新随机变量, 例如

$$A = \frac{1}{n}\sum_{k=1}^{n}(X_k - \mu)^2$$

就是典型的例子. 我们求其期望和方差. 根据独立性

$$\mathbb{E}(A) = \mathbb{E}\left((X_1 - \mu)^2\right) = \mathbb{E}\left(X_1^2 - 2X_1\mu + \mu^2\right).$$

注意依照方差的定义以及正态分布的性质

$$\mathbb{E}\left(X_1^2\right)-\mathbb{E}(X_1)^2=\mathrm{Var}(X_1) \implies \mathbb{E}\left(X_1^2\right)=\mu^2+\sigma^2,$$

代入得

$$\mathbb{E}(A)=\mu^2+\sigma^2-2\mu^2+\mu^2=\sigma^2.$$

考虑 $Y_k=X_k-\mu$ 服从 $N(0,\sigma^2)$, 有

$$\mathrm{Var}(A)=\mathrm{Var}\left(\frac{1}{n}\sum_{k=1}^{n}Y_k^2\right)=\frac{1}{n^2}\mathbb{E}\left(\left(\sum_{k=1}^{n}Y_k^2\right)^2\right)-\sigma^4.$$

对平方项展开, 并利用独立性得

$$\mathbb{E}\left(\left(\sum_{k=1}^{n}Y_k^2\right)^2\right)=\mathbb{E}\left(\sum_{k=1}^{n}Y_k^4+\sum_{i\neq j}(Y_iY_j)^2\right)=n\mathbb{E}\left(Y_1^4\right)+n(n-1)\mathbb{E}\left(Y_1^2\right)^2.$$

根据期望的定义

$$\mathbb{E}\left(Y_1^4\right)=\int_{\mathbb{R}}x^4f(x)\mathrm{d}x=\frac{1}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}}x^4\exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x.$$

作分部积分得

$$\mathbb{E}\left(Y_1^4\right)=\frac{1}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}}x^4\exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x=\frac{-\sigma^2}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}}x^3\mathrm{d}\exp\left(-\frac{x^2}{2\sigma^2}\right),$$

即得

$$\mathbb{E}\left(Y_1^4\right)=\frac{3\sigma^2}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}}x^2\exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x=3\sigma^2\mathbb{E}\left(Y_1^2\right)=3\sigma^4.$$

代入得

$$\mathrm{Var}(A)=\frac{n\mathbb{E}\left(Y_1^4\right)+n(n-1)\mathbb{E}\left(Y_1^2\right)^2}{n^2}-\sigma^4=\frac{2}{n}\sigma^4.$$

下面构造的随机变量与之对应.

Example 1.2.(正态分布的样本方差) 给定 n 维随机向量 $\mathbf{X}$, 每个分量独立同分布, 服从正态分布 $N(\mu,\sigma^2)$, 定义随机变量

$$B=\frac{1}{n-1}\sum_{k=1}^{n}(X_k-\overline{X})^2.$$

注意到可以作变形

$$
\begin{aligned}
B &= \frac{1}{n-1}\sum_{k=1}^{n}(X_k-\overline{X})^2 \\
&= \frac{1}{n-1}\sum_{k=1}^{n}\left(X_k^2-2X_k\overline{X}+\overline{X}^2\right) \\
&= \frac{1}{n-1}\left(\sum_{k=1}^{n}X_k^2-2n\overline{X}^2+n\overline{X}^2\right) \\
&= \frac{1}{n(n-1)}\left(n\sum_{k=1}^{n}X_k^2-\left(\sum_{k=1}^{n}X_k\right)^2\right) \\
&= \frac{1}{n(n-1)}\left(n\sum_{k=1}^{n}X_k^2-\sum_{k=1}^{n}X_k^2-\sum_{i\neq j}X_iX_j\right) \\
&= \frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j.
\end{aligned}
$$

取期望即得

$$\mathbb{E}(B)=\mathbb{E}\left(X_1^2\right)-\mathbb{E}(X_1)^2=\mathrm{Var}(X_1)=\sigma^2.$$

由于 X_k 同分布, 在只有一个变量时我们也直接记作 X. 为求方差, 写为

$$\mathrm{Var}(B)=\mathrm{Cov}(B,B),$$

即

$$\mathrm{Cov}\left(\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j,\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j\right).$$

依照定义协方差具有双线性, 于是可以逐项展开, 且根据对称性有

$$\mathrm{Var}(B)=\mathrm{Cov}\left(X_1^2-X_1X_2,\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j\right).$$

注意到独立变量的协方差为 0, 可知上式为

$$\frac{1}{n}\mathrm{Cov}\left(X_1^2,X_1^2-2X_1X_2\right)-\frac{1}{n}\mathrm{Cov}\left(X_1X_2,X_1^2+X_2^2-2\frac{n-2}{n-1}(X_1+X_2)X_3-\frac{2X_1X_2}{n-1}\right).$$

依照定义和对称性计算得

$$
\begin{aligned}
\mathrm{Var}(B)=&\frac{1}{n}\left(\mathrm{Cov}\left(X_1^2,X_1^2\right)-4\,\mathrm{Cov}\left(X_1^2,X_1X_2\right)\right) \\
&+\frac{1}{n(n-1)}\left(4(n-2)\,\mathrm{Cov}\left(X_1X_2,X_1X_3\right)+2\,\mathrm{Cov}\left(X_1X_2,X_1X_2\right)\right) \\
=&\frac{1}{n}\left(\mathbb{E}\left(X_1^4\right)-\mathbb{E}\left(X_1^2\right)^2-4\mathbb{E}\left(X_1^3X_2\right)+4\mathbb{E}\left(X_1^2\right)\mathbb{E}\left(X_1X_2\right)\right) \\
&+\frac{4(n-2)}{n(n-1)}\left(\mathbb{E}\left(X_1^2X_2X_3\right)-\mathbb{E}\left(X_1X_2\right)\mathbb{E}\left(X_1X_3\right)\right) \\
&+\frac{2}{n(n-1)}\left(\mathbb{E}\left(X_1^2X_2^2\right)-\mathbb{E}\left(X_1X_2\right)^2\right).
\end{aligned}
$$

依照独立性有

$$\begin{aligned}\operatorname{Var}(B) =& \frac{1}{n}\left(\mathbb{E}\left(X^4\right)-\mathbb{E}\left(X^2\right)^2-4\mathbb{E}\left(X^3\right)\mathbb{E}\left(X_1\right)+4\mathbb{E}\left(X^2\right)\mathbb{E}\left(X\right)^2\right)\\ &+\frac{4(n-2)}{n(n-1)}\left(\mathbb{E}\left(X^2\right)\mathbb{E}\left(X\right)^2-\mathbb{E}\left(X\right)^4\right)+\frac{2}{n(n-1)}\left(\mathbb{E}\left(X^2\right)^2-\mathbb{E}\left(X\right)^4\right).\end{aligned}$$

利用矩生成函数或特征函数可以计算 n 阶矩

$$\mathbb{E}\left(X\right)=\mu,\quad \mathbb{E}\left(X^2\right)=\mu^2+\sigma^2,\quad \mathbb{E}\left(X^3\right)=\mu^3+3\mu\sigma^2,\quad \mathbb{E}\left(X^4\right)=\mu^4+6\mu^2\sigma^2+3\sigma^4,$$

代入计算得

$$\operatorname{Var}(B)=\frac{2}{n-1}\sigma^4.$$

由此我们可以计算两者之间的关系.

Example 1.3.(总体方差与样本方差的相关系数) **Example 1.1.**和**Example 1.2.**中定义的随机变量 A, B, 可以计算协方差

$$\operatorname{Cov}(A,B)=\operatorname{Cov}\left((X_1-\mu)^2,\frac{1}{n}\sum_{k=1}^{n}X_k^2-\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j\right).$$

仍然依照独立性

$$\operatorname{Cov}(A,B)=\operatorname{Cov}\left((X_1-\mu)^2,\frac{1}{n}X_1^2-\frac{2}{n}X_1X_2\right)=\frac{1}{n}\operatorname{Cov}\left(X_1^2-2\mu X_1,X_1^2-2X_1X_2\right).$$

展开计算得

$$\operatorname{Cov}(A,B)=\frac{2}{n}\sigma^4.$$

依照相关系数的定义

$$\rho(A,B)=\frac{\operatorname{Cov}(A,B)}{\sqrt{\operatorname{Var}(A)\operatorname{Var}(B)}}=\frac{\frac{2}{n}\sigma^4}{\sqrt{\frac{2}{n}\sigma^4\cdot\frac{2}{n-1}\sigma^4}}=\sqrt{\frac{n-1}{n}}.$$

我们看到以上样本具有很好的性质: 独立性允许我们分别计算期望, 而同分布允许我们用对称性化简, 由此引出了如下定义.

Definition 1.2.(简单随机样本) 独立同分布 (i.i.d.) 的有限个样本称为简单随机样本.

简单随机样本的分布函数和密度函数就是

$$F_n(\mathbf{x})=\prod_{k=1}^{n}F(x_k),\quad f_n(\mathbf{x})=\prod_{k=1}^{n}f(x_k).$$

简单随机样本对还原总体分布提供了很好的条件, 这就是统计推断. 然而有限个样本不足以确定某个分布, 因此需要假定某种分布的类型. 选定某种分布类型, 例如 Poisson 分布, 正态分布等, 其所有可能分布称为分布族, 参数的全体取值称为参数空间.

利用样本可以构造出分布的若干特征, 用来近似总体分布的特征.

Definition 1.3.(统计量) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 任何一个样本的函数

$$\varphi(X_1, X_2, \ldots, X_n)$$

称为统计量.

尤其要强调的是统计量的函数中不能含有总体分布的参数, 而只能由样本和 $\mathbb{R}$ 中元以及若干函数构成. 均值 $\overline{X}$, 方差 $\mathrm{Var}(X)$, 中位数, 最大值等都是常见的统计量.

我们可以用函数编码样本的信息.

Definition 1.4.(经验分布函数) 样本 $\{X_k\}_{k=1}^n$ 的**经验分布函数 (empirical distribution function, EDF)** 定义为

$$F_n(x) = \frac{1}{n}\sum_{k=1}^{n} \chi(X_i \le x), \quad \chi(P) = \begin{cases} 1, & P = \mathbf{T}, \\ 0, & P = \mathbf{F}. \end{cases}$$

1.2 正态分布的统计量

在这一部分, 我们主要研究各个统计量作为随机变量的数值特征.

Example 1.4.(正态分布顺序统计量的期望) 设 $\{X_k\}_{k=1}^n$ 独立同分布, 服从标准正态分布 $N(0,1)$. 考虑其最大值

$$X = \max_{1\le k\le n}\{X_k\}$$

的概率分布

$$F(x) = \mathbb{P}(X \le x) = \prod_{k=1}^n \mathbb{P}(X_k \le x) = \Phi(x)^n.$$

于是期望

$$\mathbb{E}(X) = \int_{\mathbb{R}} x\mathrm{d}\mathbb{P}(X \le x) = -\int_{\mathbb{R}} x\mathrm{d}\left(1-\Phi(x)^n\right) = \int_{\mathbb{R}} \left(1-\Phi(x)^n\right)\mathrm{d}x.$$

其展开的主项为 $\sqrt{2\ln n}$.

对样本 $\{X_k\}_{k=1}^n$, 我们尤其关心以下两个先前讨论过的统计量.

Definition 1.5.(样本均值和样本方差) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 定义**样本均值**

$$\overline{X} = \frac{1}{n}\sum_{k=1}^n X_k$$

和**样本方差**

$$S^2 = \frac{1}{n-1}\sum_{k=1}^n (X_k - \overline{X})^2.$$

我们先作简要分析.

Example 1.5.(样本均值和样本方差的线性代数刻画) 给定 n 个样本 $\{X_k\}_{k=1}^n$, 注意到

$$\overline{X} = \frac{1}{n}\sum_{k=1}^n X_k = \frac{1}{n}\begin{bmatrix}1 & 1 & \cdots & 1\end{bmatrix}\begin{bmatrix}X_1\\X_2\\\vdots\\X_n\end{bmatrix} = \frac{1}{n}\mathbf{1}^T\mathbf{X},$$

以及

$$S^2 = \frac{1}{n-1}\sum_{k=1}^n (X_k - \overline{X})^2 = \frac{n}{n-1}\left(\frac{1}{n}\sum_{k=1}^n X_k^2 - \overline{X}^2\right),$$

展开得

$$S^2 = \frac{n}{n-1}\left(\frac{1}{n}\mathbf{X}^T\mathbf{X} - \frac{1}{n^2}\mathbf{X}^T\mathbf{1}\mathbf{1}^T\mathbf{X}\right) = \frac{1}{n-1}\mathbf{X}^T\left(I - \frac{1}{n}\mathbf{1}\mathbf{1}^T\right)\mathbf{X}.$$

这启示我们把 $\mathbf{1}$ 单位化为 $\mathbf{1} = \|\mathbf{1}\|\hat{\mathbf{1}} = \sqrt{n}\mathbf{e}_1$, 则样本均值和样本方差可以写为

$$\overline{X} = \frac{1}{\sqrt{n}}\mathbf{e}_1\mathbf{X}, \quad S^2 = \frac{1}{n-1}\mathbf{X}^T\left(I - \mathbf{e}_1\mathbf{e}_1^T\right)\mathbf{X}.$$

对单位向量 $\mathbf{e}_1$, 一个自然的想法是将之扩充为一组标准正交基 $\{\mathbf{e}_k\}_{k=1}^n$, 于是

$$S^2 = \frac{1}{n-1}\mathbf{X}^T\left(I - \mathbf{e}_1\mathbf{e}_1^T\right)\mathbf{X} = \frac{1}{n-1}\mathbf{X}^T\left(\sum_{k=2}^n \mathbf{e}_k\mathbf{e}_k^T\right)\mathbf{X} = \frac{1}{n-1}\sum_{k=2}^n(\mathbf{e}_k^T\mathbf{X})^2.$$

由于这是一组标准正交基, 构成正交矩阵 $Q = \begin{bmatrix}\mathbf{e}_1 & \mathbf{e}_2 & \cdots & \mathbf{e}_n\end{bmatrix}$, 于是 $\mathbf{e}_k^T\mathbf{X}$ 恰好是 $Q^T\mathbf{X}$ 的 k-分量. 这表明样本均值可以看作 $\mathbf{Y} = Q^T\mathbf{X}$ 的 1-分量, 而样本方差可以看作 $\mathbf{Y}$ 的后 $n-1$ 个分量的平方均值.

上例说明在适当的线性变换下, 样本均值和样本方差都可以看作某种均值, 从而简化讨论. 因此有必要研究一些分布下的样本在线性变换, 尤其是正交变换下的性质.

Theorem 1.1.(正态分布的正交不变性) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 独立同正态分布 $N(\mu, \sigma^2)$, 则对正交变换 Q, $\mathbf{Y} = Q\mathbf{X}$ 的各个分量也独立, 且服从正态分布. 特别地, 当 $\mu = 0$ 时, $\mathbf{Y}$ 的各个分量独立同分布 $N(0, \sigma^2)$.

Proof. 先考虑对 $\mathbf{X}$ 作一般的线性组合

$$L(\mathbf{X}) = \sum_{k=1}^n c_k X_k,$$

根据特征函数理论, 对每个 $X = X_k$ 有

$$\psi_X(t) = \mathbb{E}\left(\exp\left(\mathrm{i}tX\right)\right) = \exp\left(\mathrm{i}\mu t - \frac{1}{2}\sigma^2 t^2\right),$$

可知

$$\psi_{L(\mathbf{X})}(t) = \mathbb{E}\left(\exp\left(\mathrm{i}t\sum_{k=1}^n c_k X_k\right)\right) = \prod_{k=1}^n \mathbb{E}\left(\exp(\mathrm{i}c_k t X_k)\right),$$

代入展开得

$$\psi_{L(\mathbf{X})}(t) = \exp\left(\mathrm{i}\mu t\sum_{k=1}^n c_k - \frac{1}{2}\sigma^2 t^2\sum_{k=1}^n c_k^2\right),$$

这就说明 $L(\mathbf{X})$ 服从正态分布

$$L(\mathbf{X}) \sim N\left(\mu\sum_{k=1}^n c_k, \sigma^2\sum_{k=1}^n c_k^2\right).$$

现在考虑正交矩阵 Q, 则 $\mathbf{Y} = Q\mathbf{X}$ 的每个分量服从正态分布

$$Y_i \sim N\left(\mu\sum_{k=1}^n a_{ik}, \sigma^2\sum_{k=1}^n a_{ik}^2\right) = N\left(\mu\sum_{k=1}^n a_{ik}, \sigma^2\right).$$

为证独立性, 只要计算协方差. 根据协方差的双线性可知

$$\mathrm{Cov}(Y_i, Y_j) = \sum_{k=1}^{n}\sum_{l=1}^{n} a_{ik}a_{jl}\,\mathrm{Cov}(X_k, X_l) = \sigma^2 \sum_{k=1}^{n} a_{ik}a_{jk} = \sigma^2 (Qe_i)^T (Qe_j).$$

根据正交矩阵的性质, $i \neq j$ 时上式为 0, 于是 $\mathbf{Y}$ 各分量独立. 最后当 $\mu = 0$ 时, 代入 Y_i 的分布可知独立同分布. □

结合**Example 1.5.**的讨论, 由于样本均值和样本方差本质分别依赖 Y_1 以及 $\{Y_k\}_{k=2}^n$, 从而也是独立的. 样本均值是容易计算的.

$$\overline{X} = \sum_{k=1}^{n} \frac{1}{n} X_k \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

为了讨论样本方差, 由于这是 $n-1$ 个独立正态分布样本的平方和, 只要讨论此种形式的密度函数. 我们暂时只考虑独立同分布的情形.

Example 1.6.(正态分布的样本方差) 给定样本 $\{X_k\}_{k=1}^n$ 独立同正态分布 $N(0, \sigma^2)$, 则样本方差

$$S^2 = \frac{1}{n-1}\sum_{k=2}^{n} Y_k^2.$$

根据**Theorem 1.1.**的结果, 每个 Y_k 服从正态分布 $N(0, \sigma^2)$, 于是特征函数

$$\psi_{Y^2}(t) = \mathbb{E}\left(\exp\left(\mathrm{i}tY^2\right)\right) = \frac{1}{\sqrt{2\pi}\sigma}\int_{\mathbb{R}} \exp\left(\mathrm{i}tx^2 - \frac{1}{2\sigma^2}x^2\right)\mathrm{d}x = (1 - 2\mathrm{i}\sigma^2 t)^{-\frac{1}{2}}.$$

于是 S^2 的特征函数

$$\psi_{S^2}(t) = \left(1 - \frac{2\mathrm{i}\sigma^2}{n-1}t\right)^{-\frac{n-1}{2}}.$$

计算密度函数

$$f_{S^2}(x) = \frac{1}{2\pi}\int_{\mathbb{R}} \mathrm{e}^{-\mathrm{i}tx}\left(1 - \frac{2\mathrm{i}\sigma^2}{n-1}t\right)^{-\frac{n-1}{2}}\mathrm{d}t = \left(\frac{n-1}{2\sigma^2}\right)^{\frac{n-1}{2}} \frac{x^{\frac{n-1}{2}-1}}{\Gamma\left(\frac{n-1}{2}\right)} \exp\left(-\frac{(n-1)x}{2\sigma^2}\right).$$

1.3 χ^2 分布, t 分布与 F 分布

1.3.1 χ^2 分布

独立正态分布的平方和称为 χ^2 分布.

Definition 1.6.(χ^2 分布) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 独立同标准正态分布, 称随机变量

$$\xi = \sum_{k=1}^n X_k^2$$

服从的分布为自由度为 n 的 χ^2 分布, 记作 $\xi \sim \chi_n^2$.

我们可以计算其密度函数.

Theorem 1.2.(χ^2 分布的密度函数) 设 ξ 是服从自由度为 n 的 χ^2 分布的随机变量, 则其概率密度函数为

$$f_n(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)} x^{\frac{n}{2}-1}\mathrm{e}^{-\frac{x}{2}}, & x > 0, \\ 0, & x \le 0. \end{cases}$$

其中

$$\Gamma(t) = \int_0^{+\infty} x^{t-1}\mathrm{e}^{-x}\mathrm{d}x.$$

Proof. 依照概率分布的定义

$$F_n(x) = \mathbb{P}\left(\sum_{k=1}^n X_k^2 \le x\right) = \int_{\sum_{k=1}^n x_k^2 \le x} \left(\frac{1}{\sqrt{2\pi}}\right)^n \exp\left(-\frac{1}{2}\sum_{k=1}^n x_k^2\right) \mathrm{d}x_1 \cdots \mathrm{d}x_n.$$

考虑换元

$$\begin{cases} x_1 = \rho\cos\theta_1\cos\theta_2\cdots\cos\theta_{n-1}, \\ x_2 = \rho\cos\theta_1\cos\theta_2\cdots\sin\theta_{n-1}, \\ x_3 = \rho\cos\theta_1\cos\theta_2\cdots\sin\theta_{n-2}, \\ \cdots, \\ x_n = \rho\sin\theta_1. \end{cases}$$

相应的 Jacobi 行列式为

$$\det(J) = \rho^{n-1}\varphi(\theta),$$

其中 $\varphi(\theta)$ 表示只与 $\{\theta_k\}_{k=1}^{n-1}$ 有关的函数. 此后我们将任意常数记作待定的 C_n, 得到

$$F_n(x) = C_n \int_{\rho^2 \le x} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1}\varphi(\theta)\mathrm{d}\rho\mathrm{d}\theta_1\cdots\mathrm{d}\theta_{n-1}.$$

注意到区域 $\rho^2 \le x$ 相当于 $\rho \in [0, \sqrt{x}]$ 而 θ_k 在固定范围内变化, 即 θ 的范围不依赖于 x, 从而被视作常数 C_n 的部分, 于是

$$F_n(x) = \begin{cases} C_n \int_0^{\sqrt{x}} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} \mathrm{d}\rho, & x > 0, \\ 0, & x \le 0. \end{cases}$$

由于这是概率分布, 令 $x \to +\infty$ 必定得到 1, 即

$$C_n \int_0^{+\infty} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} \mathrm{d}\rho = 1.$$

作换元 $r = \frac{1}{2}\rho^2$ 可以看出

$$C_n \int_0^{+\infty} \mathrm{e}^{-r} (2r)^{\frac{n-1}{2}} (2r)^{-\frac{1}{2}} \mathrm{d}r = C_n 2^{\frac{n}{2}-1} \Gamma\left(\frac{n}{2}\right) = 1.$$

这就给出了 C_n 的值. 现在只要对分布函数求导

$$\frac{\mathrm{d}}{\mathrm{d}x} \int_0^{\sqrt{x}} \exp\left(-\frac{1}{2}\rho^2\right) \rho^{n-1} \mathrm{d}\rho = x^{\frac{n-1}{2}} \mathrm{e}^{-\frac{x}{2}} \frac{1}{2\sqrt{x}},$$

代入 C_n 的值即证. □

我们也称以

$$f(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} \mathrm{e}^{-\frac{x}{\beta}}$$

为密度函数的分布为参数 α, β 的 Γ 分布, 记作 $X \sim \Gamma(\alpha, \beta)$. 则 χ^2 分布相当于 $\Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$. 由于指数分布的密度函数为

$$f(x) = \lambda \mathrm{e}^{\lambda x}, \quad x > 0,$$

因此自由度为 2 的 χ^2 分布恰好是指数分布 $\mathrm{Exp}\left(\frac{1}{2}\right)$. 一般的指数分布可以通过变换改写为 $\mathrm{Exp}\left(\frac{1}{2}\right)$ 的形式.

利用密度函数可以计算 k 阶矩.

Theorem 1.3.(χ^2 分布的 k 阶矩) 设 ξ 是服从自由度为 n 的 χ^2 分布的随机变量, 则对任意 $k > -\frac{n}{2}$, k 阶矩

$$\mathbb{E}\left(\xi^k\right) = 2^k \frac{\Gamma\left(\frac{n}{2} + k\right)}{\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 取 $n = 1$ 得到标准正态分布的偶数阶矩

$$\mathbb{E}\left(X^{2k}\right) = \mathbb{E}\left(\xi^k\right) = (2k-1)!!.$$

Proof. 利用密度函数

$$\mathbb{E}\left(\xi^k\right)=\int_{\mathbb{R}} x^k f_n(x)\mathrm{d}x=\int_0^{+\infty}\frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)}x^{\frac{n}{2}+k-1}\mathrm{e}^{-\frac{x}{2}}\mathrm{d}x=2^k\frac{\Gamma\left(\frac{n}{2}+k\right)}{\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 取 $n=1$ 得 $\xi=X^2$, 于是

$$\mathbb{E}\left(X^{2k}\right)=2^k\frac{\Gamma\left(\frac{1}{2}+k\right)}{\Gamma\left(\frac{1}{2}\right)}=(2k-1)!!.$$

□

我们回顾**Example 1.3.**中计算的相关系数.

Example 1.7.(总体方差与样本方差的相关系数) **Example 1.1.**和**Example 1.2.**中定义的随机变量

$$A=\frac{1}{n}\sum_{k=1}^n(X_k-\mu)^2,\quad B=\frac{1}{n-1}\sum_{k=1}^n(X_k-\overline{X})^2.$$

观察相关系数的定义

$$\rho(A,B)=\frac{\mathrm{Cov}(A,B)}{\sqrt{\mathrm{Var}(A)\,\mathrm{Var}(B)}}$$

可知 $\rho(\alpha A,\beta B)=\rho(A,B)$. 于是只要计算

$$\rho\left(\sum_{k=1}^n(X_k-\mu)^2,\sum_{k=1}^n(X_k-\overline{X})^2\right)$$

即可. 注意到

$$\sum_{k=1}^n(X_k-\mu)^2=\sum_{k=1}^n(X_k-\overline{X})^2+n\left(\overline{X}-\mu\right)^2,$$

根据**Theorem 1.1.**的结果, 样本均值 $\overline{X}$ 和样本方差 S^2 独立, 因此根据协方差的双线性只要计算

$$\frac{\mathrm{Cov}\left(\sum\limits_{k=1}^n(X_k-\overline{X})^2,\sum\limits_{k=1}^n(X_k-\overline{X})^2\right)}{\sqrt{\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\mu)^2\right)\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\overline{X})^2\right)}}=\sqrt{\frac{\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\overline{X})^2\right)}{\mathrm{Var}\left(\sum\limits_{k=1}^n(X_k-\mu)^2\right)}}.$$

根据**Theorem 1.1.**的结果, 两者分别相当于自由度为 $n-1$ 和 n 的 χ^2 分布, 于是根据**Theorem 1.3.**可求出

$$\rho(A,B)=\sqrt{\frac{n-1}{n}}.$$

1.3.2 t 分布

正态分布与独立正态分布的平方平均之商称为 t 分布.

Definition 1.7.(t 分布) 给定 n 个样本 $\{X_k\}_{k=1}^n$ 和一个样本 Y 独立同标准正态分布, 称随机变量

$$T = Y\left(\frac{1}{n}\sum_{k=1}^n X_k^2\right)^{-\frac{1}{2}}$$

服从的分布为自由度为 n 的 t 分布, 记作 $\xi \sim t_n$.

我们可以计算其密度函数.

Theorem 1.4.(t 分布的密度函数) 设 T 是服从自由度为 n 的 t 分布的随机变量, 则其概率密度函数为

$$f_n(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{n\pi}}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}.$$

Proof. 依照概率分布的定义

$$F_n(t) = \mathbb{P}\left(\frac{\sqrt{n}Y}{\sqrt{\xi}} \le t\right) = \int_{\frac{\sqrt{n}y}{\sqrt{x}}\le t} \frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{y^2}{2}}\frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)}x^{\frac{n}{2}-1}\mathrm{e}^{-\frac{x}{2}}\mathrm{d}x\mathrm{d}y.$$

考虑换元

$$\begin{cases} u = \frac{y}{\sqrt{x}}, \\ v = \sqrt{x}. \end{cases}$$

相应的 Jacobi 行列式为

$$\det(J) = \det\left(\begin{bmatrix} 0 & 2v \\ v & u \end{bmatrix}\right) = -2v^2,$$

于是

$$F_n(t) = \int_{\sqrt{n}u\le t, v\ge 0} \frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{u^2v^2}{2}}\frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)}v^{n-2}\mathrm{e}^{-\frac{1}{2}v^2}2v^2\mathrm{d}u\mathrm{d}v.$$

整理得

$$F_n(t) = \frac{1}{2^{\frac{n}{2}-1}\Gamma\left(\frac{n}{2}\right)}\int_{-\infty}^{\frac{t}{\sqrt{n}}}\left(\int_0^{+\infty}\frac{1}{\sqrt{2\pi}}v^n\mathrm{e}^{-\frac{v^2}{2}(u^2+1)}\mathrm{d}v\right)\mathrm{d}u.$$

作换元 $z = \frac{1}{2}(u^2+1)v^2$ 可得括号内为

$$\int_0^{+\infty}\frac{1}{\sqrt{2\pi}}\left(\sqrt{\frac{2z}{u^2+1}}\right)^n\mathrm{e}^{-z}\frac{1}{\sqrt{2z(u^2+1)}}\mathrm{d}z.$$

利用 Gamma 函数可以写为

$$\frac{2^{\frac{n-1}{2}}}{\sqrt{2\pi}(u^2+1)^{\frac{n+1}{2}}}\int_0^{+\infty} z^{\frac{n-1}{2}}\mathrm{e}^{-z}\mathrm{d}z = \frac{2^{\frac{n-1}{2}}\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{2\pi}(u^2+1)^{\frac{n+1}{2}}}.$$

代入得

$$F_n(t) = \frac{1}{2^{\frac{n}{2}-1}\Gamma\left(\frac{n}{2}\right)}\int_{-\infty}^{\frac{t}{\sqrt{n}}} \frac{2^{\frac{n}{2}-1}\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}(u^2+1)^{\frac{n+1}{2}}}\mathrm{d}u = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}\Gamma\left(\frac{n}{2}\right)}\int_{-\infty}^{\frac{t}{\sqrt{n}}}(u^2+1)^{-\frac{n+1}{2}}\mathrm{d}u.$$

对 t 求导即得密度函数

$$f_n(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}.$$

□

特别地, 如果取 $n=1$, 则变为

$$f_1(t) = \frac{1}{\pi(1+t^2)}$$

是 Cauchy 分布. 令 $n\to\infty$, 则依照 e 的定义和 Stirling 公式变为

$$\lim_{n\to\infty} f_n(t) = \frac{\sqrt{\frac{n}{2}}}{\sqrt{n\pi}}\exp\left(-\frac{1}{2}t^2\right) = \frac{1}{\sqrt{2\pi}}\exp\left(-\frac{1}{2}t^2\right),$$

即标准正态分布.

利用密度函数可以计算 k 阶矩.

Theorem 1.5.(t 分布的 k 阶矩) 设 T 是服从自由度为 n 的 t 分布的随机变量, 则对任意 $k<n$, k 阶矩

$$\mathbb{E}\left(T^k\right) = \begin{cases} n^{\frac{k}{2}}\frac{\Gamma\left(\frac{k+1}{2}\right)\Gamma\left(\frac{n-k}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\Gamma\left(\frac{1}{2}\right)}, & 2\mid k, \\ 0, & 2\nmid k. \end{cases}$$

Proof. 利用密度函数

$$\mathbb{E}\left(T^k\right) = \int_{\mathbb{R}} t^k f_n(t)\mathrm{d}t = \int_{\mathbb{R}} t^k \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}\mathrm{d}t.$$

当 $2\nmid k$ 时, 被积函数是奇函数, 从而积分值为 0. 当 $2\mid k$ 时, 考虑换元 $z=\frac{t^2}{n}$, 恰好得到 Beta 函数

$$\mathbb{E}\left(T^k\right) = \frac{n^{\frac{k}{2}}\Gamma(\frac{n+1}{2})}{\sqrt{\pi}\Gamma(\frac{n}{2})}\int_0^{+\infty} z^{\frac{k-1}{2}}(1+z)^{-\frac{n+1}{2}}\mathrm{d}z = \frac{n^{\frac{k}{2}}\Gamma(\frac{n+1}{2})}{\sqrt{\pi}\Gamma(\frac{n}{2})}B\left(\frac{k+1}{2},\frac{n-k}{2}\right),$$

展开为 Gamma 函数即证. □

1.3.3 F 分布

独立正态分布平方的均值之商称为 F 分布.

Definition 1.8.(F 分布) 给定 $m+n$ 个样本 $\{X_i\}_{i=1}^m$ 和 $\{Y_j\}_{j=1}^n$ 独立同标准正态分布, 称随机变量

$$Z=\frac{\frac{1}{m}\sum_{i=1}^m X_i^2}{\frac{1}{n}\sum_{j=1}^n X_j^2}$$

服从的分布为参数 m,n 的 F 分布, 记作 $Z\sim F_{m,n}$.

我们仍然计算其密度函数.

Theorem 1.6.(F 分布的密度函数) 设 Z 是服从参数 m,n 的 F 分布的随机变量, 则其概率密度函数为

$$f_{m,n}(t)=\begin{cases}\frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}m^{\frac{m}{2}}n^{\frac{n}{2}}t^{\frac{m}{2}-1}(n+mt)^{-\frac{m+n}{2}}, & t>0,\\ 0, & t\le 0.\end{cases}$$

Proof. 我们记 X_i 的平方和为 X, Y_j 的平方和为 Y, 则分别服从自由度为 m,n 的 χ^2 分布. 依照概率分布的定义

$$F_{m,n}(t)=\mathbb{P}\left(\frac{X/m}{Y/n}\le t\right)=\int_{\frac{x/m}{y/n}\le t}\frac{1}{2^{\frac{m+n}{2}}\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}x^{\frac{m}{2}-1}y^{\frac{n}{2}-1}\mathrm{e}^{-\frac{x+y}{2}}\mathrm{d}x\mathrm{d}y.$$

考虑换元

$$\begin{cases}u=\frac{x}{y},\\ v=y.\end{cases}$$

相应的 Jacobi 行列式为

$$\det(J)=\det\left(\begin{bmatrix}0 & 1\\ v & u\end{bmatrix}\right)=-v,$$

即得

$$F_{m,n}(t)=\int_{0\le u\le\frac{m}{n}t,v\ge 0}\frac{1}{2^{\frac{m+n}{2}}\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}(uv)^{\frac{m}{2}-1}v^{\frac{n}{2}-1}\mathrm{e}^{-\frac{(u+1)v}{2}}v\mathrm{d}u\mathrm{d}v.$$

整理得

$$F_{m,n}(t)=\int_0^{\frac{m}{n}t}\left(\frac{u^{\frac{m}{2}-1}}{2^{\frac{m+n}{2}}\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\int_0^{+\infty}v^{\frac{m+n}{2}-1}\mathrm{e}^{-\frac{(u+1)v}{2}}\mathrm{d}v\right)\mathrm{d}u.$$

采用同样的方法作换元 $z=\frac{(u+1)v}{2}$ 可得

$$\int_0^{+\infty}v^{\frac{m+n}{2}-1}\mathrm{e}^{-\frac{(u+1)v}{2}}\mathrm{d}v=\frac{2^{\frac{m+n}{2}}\Gamma\left(\frac{m+n}{2}\right)}{(u+1)^{\frac{m+n}{2}}}.$$

于是

$$F_{m,n}(t)=\frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\int_0^{\frac{m}{n}t}\frac{u^{\frac{m}{2}-1}}{(u+1)^{\frac{m+n}{2}}}\mathrm{d}u.$$

求导即得密度函数. □

依照定义即知 $F_{1,n}$ 相当于服从 t_n 分布的随机变量的平方的分布, $F_{n,m}$ 相当于服从 $F_{m,n}$ 分布的随机变量的倒数的分布.

我们仍然计算 k 阶矩.

Theorem 1.7.(F 分布的 k 阶矩) 设 Z 是服从参数 m,n 的 F 分布的随机变量, 则对任意 $0<k<\frac{n}{2}$, k 阶矩

$$\mathbb{E}\left(Z^k\right)=\left(\frac{n}{m}\right)^k\frac{\Gamma\left(\frac{m}{2}+k\right)\Gamma\left(\frac{n}{2}-k\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}.$$

特别地, 当 $n>2$ 和 $n>4$ 时有

$$\mathbb{E}(Z)=\frac{n}{n-2},\quad \mathrm{Var}(Z)=\frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}.$$

Proof. 根据独立性展开

$$\mathbb{E}\left(Z^k\right)=\left(\frac{n}{m}\right)^k\mathbb{E}\left(X^k\right)\mathbb{E}\left(Y^{-k}\right).$$

根据**Theorem 1.3.**的结果有

$$\mathbb{E}\left(X^k\right)=2^k\frac{\Gamma\left(\frac{m}{2}+k\right)}{\Gamma\left(\frac{m}{2}\right)},\quad \mathbb{E}\left(Y^{-k}\right)=2^{-k}\frac{\Gamma\left(\frac{n}{2}-k\right)}{\Gamma\left(\frac{n}{2}\right)},$$

代入即证. □

对正态分布的数据而言, 其样本均值和样本方差恰好服从正态分布和 χ^2 分布, 因此作商恰好是 t 分布和 F 分布, 这刻画了数据波动程度的关系.

Chapter 2

统计估计

Chapter 3

假设检验

Chapter 4

决策理论